

CAHIER DES CHARGES

Projet de Machine Learning & Deep Learning

Compétition Intra-Promotion sur Dataset Kaggle

1. Contexte et Objectifs

Inspiré des compétitions Kaggle, vous travaillerez tous sur le même jeu de données, ce qui garantit une évaluation équitable des étudiants.

Les objectifs pédagogiques sont :

- Maîtriser l'ensemble du pipeline d'un projet de data science (de la donnée brute au modèle déployable).
- Appliquer et comparer les algorithmes vus en cours : algorithmes ML classiques, ANN, RNN et CNN.
- Développer l'esprit critique dans l'analyse et l'interprétation des résultats.
- S'initier à la compétition et à la comparaison objective de modèles via des métriques standardisées.
- Produire un rapport technique clair.

2. Dataset & Accès aux Données

2.1 Source

Le jeu de données utilisé est celui de Kaggle intitulé *Segmented and Preprocessed ECG Signals for Heartbeat Classification*. Il a notamment servi à explorer la classification des battements cardiaques avec des réseaux de neurones profonds.

Tous les étudiants travaillent sur ce même jeu de données, accessible à l'adresse suivante :

<https://www.kaggle.com/datasets/shayanfazeli/heartbeat?resource=download>

3. Livrables Attendus

3.1 Notebook Jupyter / Script Python

Le code source complet et documenté doit être soumis. Il doit être exécutable de bout en bout et reproduire exactement les résultats présentés dans le rapport.

Structure minimale du notebook :

1. Importation des bibliothèques et configuration de l'environnement
2. Chargement et premier aperçu des données
3. Analyse Exploratoire des Données (EDA)
4. Préparation et prétraitement des données
5. Modélisation (un ou plusieurs modèles ML/DL)
6. Évaluation et comparaison des modèles

3.2 Rapport Technique (PDF)

Le rapport est un document structuré. Il doit être rédigé en français ou en anglais, avec une qualité rédactionnelle soignée.

Sections obligatoires du rapport :

- Introduction : contexte du problème, objectifs, description du dataset.
- Analyse Exploratoire (EDA) : statistiques descriptives, distributions, corrélations, visualisations commentées.
- Préparation des données : nettoyage, gestion des valeurs manquantes, encodage, normalisation, feature engineering.
- Architecture(s) proposée(s) : description des modèles retenus et justification du choix.
- Expérimentations & résultats : métriques, courbes d'apprentissage, matrices de confusion, comparatifs.
- Discussion : analyse des erreurs, limites du modèle.
- Conclusion : synthèse des apprentissages.
- Références : bibliographie et sources utilisées.

3.3 Modalités de Soumission

La soumission finale doit être déposée sur Classroom et comprendre :

- Un dossier compressé (.zip) nommé : NOM_Prenom_ProjetIA.zip
- Le notebook Jupyter (.ipynb) ou le script Python (.py) commenté
- Le rapport technique au format PDF

Toute forme de copie de code ou de partage de résultats entre étudiants est strictement interdite et entraînera la note de 0 pour les parties concernées.

- L'utilisation d'outils d'IA génératives (ChatGPT, Claude, Copilot...) est autorisée pour la compréhension et le débogage, mais le code et le rapport doivent refléter la compréhension personnelle de l'étudiant.
- Toute aide externe (tutoriels, papers, bibliothèques) doit être citée dans les références.

3.4 Recommandations

- Analysez systématiquement les valeurs manquantes, les outliers et les déséquilibres de classes.
- Testez plusieurs stratégies d'encodage et de normalisation.
- Documentez chaque décision de prétraitement dans votre rapport.
- Commencez par un modèle simple (baseline) avant d'aller vers des architectures complexes.
- Utilisez la validation croisée (cross-validation) pour estimer la performance réelle.
- Évitez le sur-apprentissage : surveillez l'écart entre train loss et validation loss.
- Documentez vos expériences : tenez un journal des configurations testées et des résultats obtenus.
- Chaque figure doit être accompagnée d'une légende et d'un commentaire analytique.
- Soyez critique : une analyse honnête des limites de votre modèle est valorisée.
- Illustrez votre démarche itérative : montrez l'amélioration progressive de vos modèles.